

Relatório Final: Reconhecimento de Atividade Humana

Desafio 11 — Machine Learning

Professora: Ma. Nathália A. Lima

Alunos: Daniel Costa (RA: 1989218), Gustavo Henrique (RA: 1992080), Renan Caixeta (RA: 2011940)

1. Introdução

Este relatório apresenta a solução atualizada do desafio multiclasse de atividades humanas, utilizando o dataset UCI HAR. Os dados foram coletados de 30 voluntários através de sensores de acelerômetro e giroscópio acoplados a smartphones, com o objetivo de mapear movimentos físicos por meio de aprendizado de máquina.

2. Descrição do Dataset

Atributo	Valor
Amostras Totais	10.299 (7.352 de treino + 2.947 de teste)
Features	561 (domínio do tempo e frequência)
Classes	6 atividades humanas
Sensores	Acelerômetro e Giroscópio

3. Análise Exploratória (EDA)

A etapa de EDA buscou entender a distribuição das classes e os perfis sensoriais de cada atividade para orientar o pré-processamento e a modelagem.





Figura 1: Distribuição e proporção das 6 classes de atividades. Nota-se um leve desbalanceamento (proporção 0.79 entre minoritária e majoritária).




Figura 2: Matriz de Correlação das Atividades. Atividades dinâmicas e estáticas formam blocos fortemente correlacionados.




Figura 3: Boxplots das principais features por atividade, destacando a capacidade de separação linear e não-linear dos sensores.



4. Pré-processamento e Feature Engineering

- O pipeline original entregou 561 features estruturadas.
- Foram removidas features quase-constantes utilizando a técnica de `VarianceThreshold` para otimizar o espaço dimensional.
- Os dados foram padronizados utilizando o `StandardScaler`, etapa crucial para algoritmos baseados em hiperplanos e distâncias (SVC e KNN).

5. Comparação de Modelos e Resultados



Os hiperparâmetros foram otimizados rigorosamente. A tabela abaixo e as visualizações confirmam a superioridade do **SVC Tunado** nas métricas de performance.

Modelo	Acurácia	Precisão Macro	Recall Macro	F1-Score Macro	Tempo (s)
KNN Tunado	0.9612	0.9636	0.9618	0.9624	~0.19
SVC-RBF Tunado	0.9903	0.9906	0.9901	0.9909	~1.43
Random Forest Tunado	0.9777	0.9781	0.9789	0.9783	~0.04



6. Análise de Erros e Avaliação por Classes

A análise das matrizes de confusão e das curvas ROC revela as áreas de maior sensibilidade preditiva, particularmente a distinção complexa entre atividades de repouso como *Sitting* e *Standing*.



7. Inteligência de Sensores e Feature Importance

Utilizando a explicabilidade provida pelo Random Forest, mapeamos as features e os sensores que mais contribuem para as decisões do modelo.




Figura 8: Top 20 Features mais importantes (Random Forest). Features baseadas na gravidade capturada pelo acelerômetro dominam o topo.




Figura 9: Densidade de importância por tipo de sensor. O Acelerômetro é responsável por cerca de 79% da inteligência preditiva.

8. Conclusão e Escolha do Modelo Final

Após a análise detalhada do projeto, incluindo tuning de hiperparâmetros e minuciosa verificação visual de matrizes de confusão e métricas intra-classe, a escolha técnica final é o **SVC Tunado (Kernel RBF)**.

Justificativa da Escolha:

A métrica que definiu e priorizou a escolha foi o **F1-Score Macro (99,09%)**. Em um cenário onde a proporção de instâncias varia entre classes (como *Laying* e *Walking Downstairs*), o F1-Score Macro assegura que o modelo tenha o melhor equilíbrio possível entre penalizar Falsos Positivos e Falsos Negativos para *todas as atividades* de maneira igualitária. O SVC demonstrou ser o único algoritmo capaz de virtualmente eliminar a sobreposição entre as zonas de confusão (Sitting vs Standing), validando que o custo em tempo de inferência é compensado pela entrega de uma confiabilidade preditiva no estado-da-arte.